Inteligência Artificial - Notas de aula

Raoni F. S. Teixeira

Aula 3 - Busca Local

1 Introdução

Nesta aula, vamos estudar agentes que procuram estados específicos sem examinar todo o ambiente. Em vez de analisar todas as possibilidades, eles focam apenas em partes do espaço de busca, movendo-se entre estados até encontrar uma solução ótima.

Se cada estado do ambiente s tiver uma pontuação $f(s)$, o agente buscará o estado com a maior pontuação possível:

$$\operatorname*{argmax}_{s \in \mathcal{S}} f(s). \tag{1}$$

Esse processo é chamado de busca local.

As seções seguintes examinam três algoritmos. Outros exemplos podem ser encontrados em [RN09, KW19].

2 Subida da encosta

Pense em escalar uma montanha para alcançar o pico mais alto. A cada passo, você avalia os picos vizinhos e escolhe aquele com a maior elevação, até que não existam opções melhores.

Essa é a essência do algoritmo de subida da encosta. Ele começa em um estado aleatório s e, a cada passo, move-se para o vizinho com a maior pontuação, analisando apenas os estados próximos. O processo termina quando atinge um ótimo ou quando o número máximo de iterações é alcançado.

A Figura 1 mostra o funcionamento do algoritmo para uma função com dois máximos. A cor vermelha indica o estado solução (s) e a cor preta mostra os vizinhos imediatos. A cada iteração, s se move para o estado vizinho com a melhor pontuação. Quando o algoritmo termina (Figura 1f), a pontuação de s é maior que a pontuação de todos os seus vizinhos — máximo local.

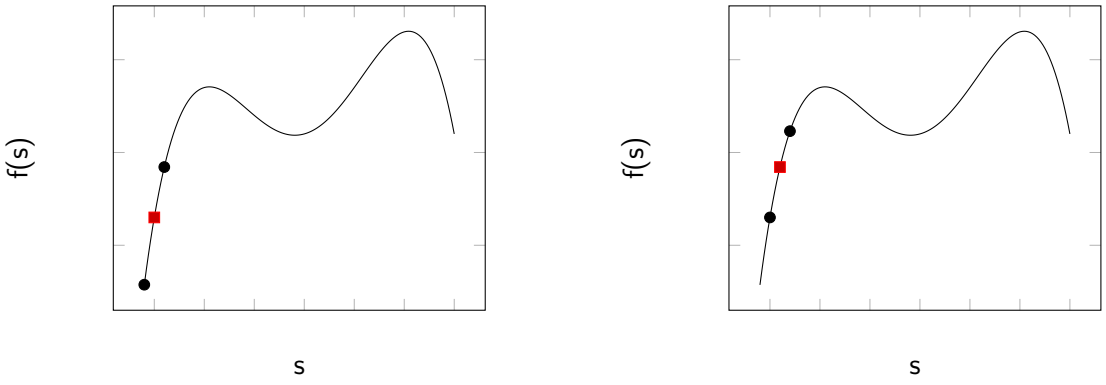

(a) Iteração 1.

(b) Iteração 2.

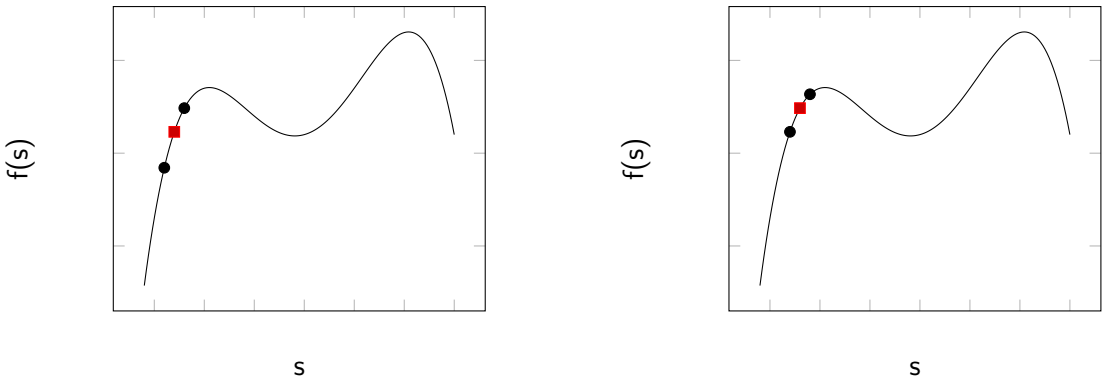

(c) Iteração 3.

(d) Iteração 4.

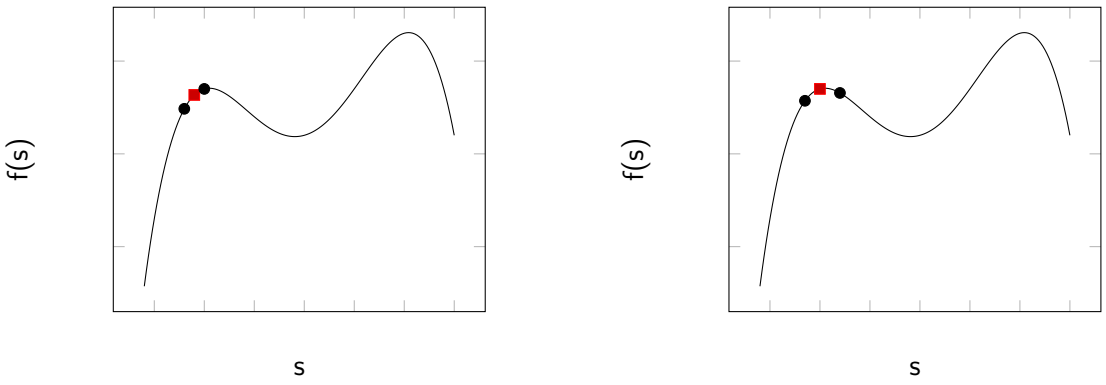

(e) Iteração 5.

(f) Iteração 6.

Figura 1: Seis iterações do algoritmo subida da encosta para um função f com dois mínimos. As cores vermelha e preta indicam respectivamente, estados em análise e vizinhos. A cada iteração, a solução se move para o estado vizinho com a melhor pontuação.

O pseudo-código a seguir apresenta esse algoritmo usando uma função VIZINHANCA que devolve os vizinhos de um estado.

```
SUBIDAENCOSTA(f, max-it)
 1  s ← estado aleatório
 2  it ← 0
 3  while it < max-iter do
 4       melhor-vizinho ← s
 5       for each estado u ∈ VIZINHANCA(s) do
 6            if f(u) > f(melhor-vizinho) then
 7                 melhor-vizinho ← u
 8       if f(melhor-vizinho) > f(s) then
 9            s ← melhor-vizinho
10       else
11            break
12       it ← it + 1
13  return s
```

Para aplicar esse algoritmo a problemas reais, você precisa definir três elementos:

1. **Representação dos estados:** como os estados serão descritos?
2. **Vizinhança:** quais estados próximos serão considerados?
3. **Função objetivo f:** como avaliar a qualidade de um estado?

O Roteiro 3 mostra um exemplo de definição para o problemas da *N-Damas*.

3 Tempera Simulada

O algoritmo de Tempera Simulada (*Simulated Annealing*) é uma técnica inspirada no processo de recozimento de metais, onde o material é aquecido e, em seguida, resfriado de forma controlada. O método é utilizado para encontrar soluções aproximadas em problemas de otimização, especialmente quando o espaço de busca possui múltiplos ótimos locais.

Ao contrário da Subida da Encosta, que pode ficar preso em ótimos locais, a Tempera Simulada permite movimentos que pioram a solução temporariamente, aumentando a chance de encontrar o ótimo global.

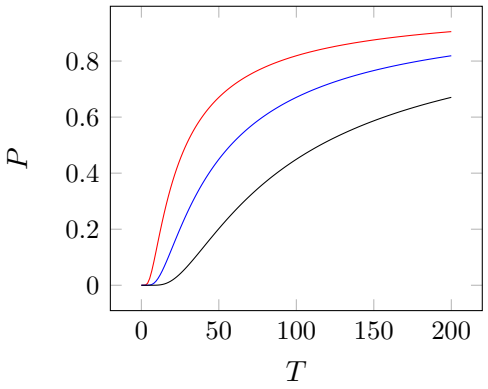

Figura 2: Probabilidade P em função da temperatura T para diferentes valores de ΔE. As curvas preta, azul e vermelha correspondem a $\Delta E = 20$, 40 e 80. À medida que T diminui, P também reduz, tornando o algoritmo mais conservador na aceitação de estados piores.

A cada iteração, o algoritmo escolhe aleatoriamente um vizinho do estado atual. Se o vizinho apresentar uma pontuação melhor, ele é aceito como o novo estado. Caso contrário, o algoritmo pode aceitá-lo com base em uma probabilidade que depende da temperatura atual e da diferença de pontuação entre os estados.

Essa probabilidade é dada pela fórmula:

$$P(\Delta E, T) = e^{-\Delta E/T},$$

em que

- ΔE é a diferença de pontuação ($f(\text{vizinho}) - f(\text{atual})$) e
- T é a temperatura atual.

A Figura 2 exibe o gráfico da função P para diferentes valores de ΔE, variando T. As curvas preta, azul e vermelha correspondem a ΔE igual a 20, 40 e 80, respectivamente. Em todos os casos, conforme a temperatura T diminui, a probabilidade de aceitar estados piores P também se reduz, tornando o algoritmo mais conservador.

O algoritmo pode ser descrito da seguinte forma:

```
TEMPERASIMULADA(f, T_inicial, taxa-resfriamento, max-it)
 1  s ← estado aleatório
 2  T ← T_inicial
 3  it ← 0
 4  while it < max-iter do
 5      vizinho ← SELECIONARVIZINHO(s)
 6      ΔE ← f(vizinho) − f(s)
 7      if ΔE > 0 then
 8          s ← vizinho
 9      else
10          if RANDOM(0, 1) < e^{−ΔE/T} then
11              s ← vizinho
12      T ← T × taxa-resfriamento
13      it ← it + 1
14  return s
```

Os parâmetros são:

- **Estado inicial** (s_{inicial}): Ponto de partida do algoritmo.
- **Temperatura inicial** (T_{inicial}): Define a probabilidade inicial de aceitar estados piores.
- **Taxa de resfriamento** ($\text{taxa}_{\text{resfriamento}}$): Controla a redução da temperatura a cada iteração.
- **Número máximo de iterações** (max_{iter}): Limita a execução do algoritmo.

A função RANDOM gera um número real no intervalo $[0, 1]$, e a função SELECIONARVIZINHO escolhe aleatoriamente um estado vizinho para continuar a busca. O Roteiro 3 apresenta um exemplo aplicado ao problema das N-Damas.

Tanto a subida da encosta quanto a têmpera simulada limitam a busca a uma única região do espaço. No entanto, a têmpera simulada aprimora a subida da encosta ao permitir escapes controlados de ótimos locais, aumentando as chances de encontrar a solução global. O próximo algoritmo, o Algoritmo Genético, adota uma abordagem diferente: em vez de focar em uma única região, ele explora múltiplos pontos do espaço de busca simultaneamente.

4 Algoritmo Genético

Algoritmo genético é um método iterativo de otimização que opera localmente sobre múlltiplas regiões do espaço de busca, combinando as informações dos estados dessas regiões para evitar

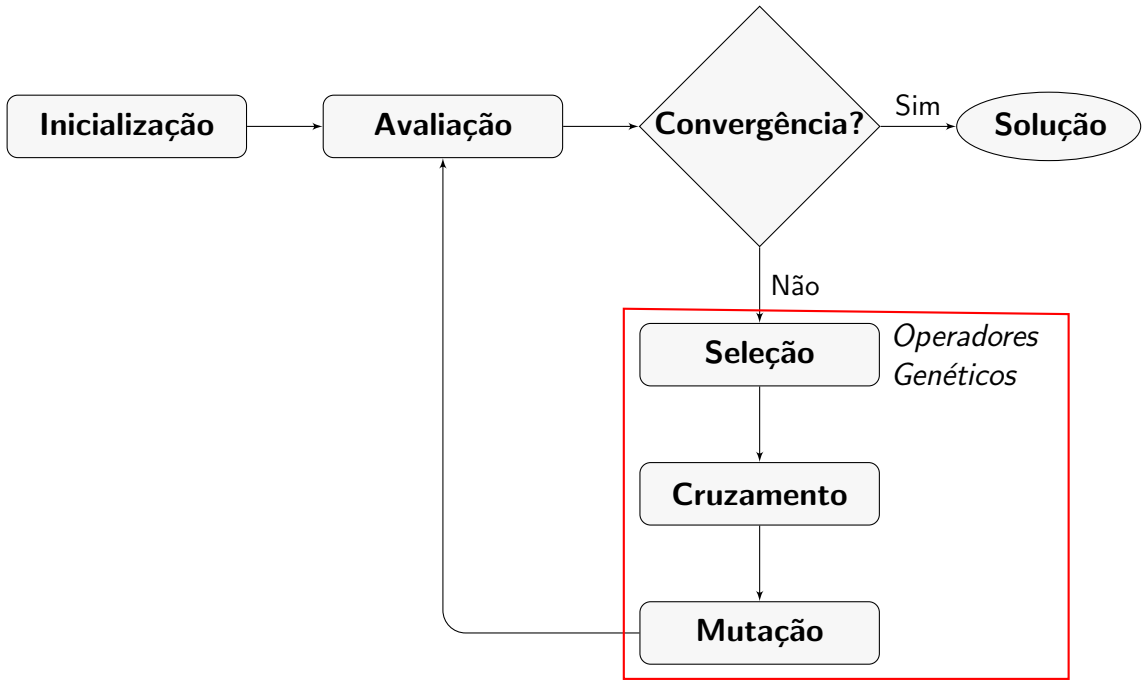

Figura 3: Algoritmo genético. O algoritmo termina quando um critério de convergência é atingido.

minimos locais.

Inspirado na biologia evolutiva, o conjunto de estados analisados é chamado de **população** e cada ciclo de iteração é uma **geração**. Cada estado é chamado de *indivíduo* e é representado por uma sequência de *cromossomos* — um vetor de números. Operações denominadas *seleção*, *cruzamento* e *mutação* produzem uma nova população combinando e alterando os vetores da população atual.

O algoritmo consiste nos passos do fluxograma da Figura 3:

- **Inicialização:** define uma população inicial composta por M indivíduos gerados aleatoriamente. Essa população deve estar bem distribuída pelo espaço de busca, aumentando as chances de encontrar uma solução. Dois parâmetros são definidos nesta etapa: (a) a distribuição utilizada na amostragem e (b) o número de amostras M. Um valor maior de M melhora a representatividade do espaço, mas também aumenta o consumo de memória.

- **Avaliação:** cada indivíduo da população é avaliado por uma função f, que retorna um número real representando sua qualidade. Seguindo a inspiração biológica, a função de avaliação é chamada de *fitness*. O algoritmo termina quando encontra um indivíduo ótimo ou atinge o número máximo de iterações.

- **Seleção:** escolhe os indivíduos mais bem avaliados para atuarem como pais da próxima geração. A seleção é realizada aleatoriamente, mas com maior probabilidade para indivíduos com melhores valores de f.
- **Cruzamento:** combina os cromossomos dos indivíduos selecionados para criar novos descendentes. A Figura 4 ilustra essa operação em torno de um ponto de cruzamento (k), um número sorteado aleatoriamente no intervalo $[0, N[$. O cruzamento concatena os vetores $v[0 \ldots k]$ e $v[k+1 \ldots N-1]$ dos pais, formando os descendentes.
- **Mutação:** altera aleatoriamente o valor de algum cromossomo de um indivíduo. A taxa de mutação define a probabilidade de essa alteração ocorrer. Uma taxa maior aumenta a chance de mutação. Tanto a posição do cromossomo quanto seu novo valor são determinados de forma aleatória e uniforme.

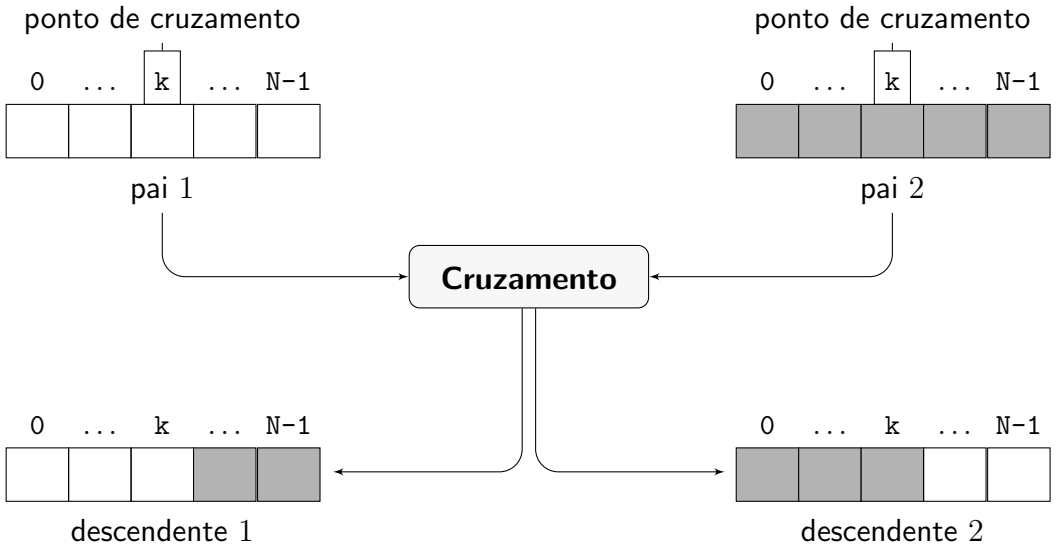

Figura 4: Operação de cruzamento. Os descendentes são uma combinação dos pais.

A aplicação dessas operações requer uma representação vetorial (cada estado é um vetor de números, *bits* etc) e uma função de avaliação, como mostra o exemplo do Roteiro 3.

Deixando de lado a terminologia e focando no processo de otimização, um algoritmo genético é um processo iterativo que explora várias regiões do espaço de busca ao mesmo tempo. A cada iteração, operadores genéticos geram um novo conjunto de pontos a partir do conjunto anterior. Esses novos pontos podem ser semelhantes ou não aos anteriores, dependendo principalmente do grau de aleatoriedade introduzido pela mutação.

5 Discussão Final

Cada um dos algoritmos apresenta vantagens e desvantagens. A escolha do algoritmo depende das características do problema e das restrições como, por exemplo, o tempo disponível e precisão necessária. A Subida da Encosta é ideal para problemas diretos e bem definidos. Já o Algoritmo Genético e a Têmpera Simulada são mais indicados para problemas que exigem maior flexibilidade e capacidade de exploração.

6 Exercícios

Utilize o código do Roteiro 3 para fazer experimentos e responder as questões abaixo.

1. Por que você acha que a seleção é tão importante no algoritmo genético? Como ela pode influenciar o sucesso do processo evolutivo?
2. Por que a mutação é importante? Como você definiria a taxa de mutação se suspeitasse que existe uma solução ainda melhor que encontrada pelo algoritmo?

Referências

[KW19] Mykel J. Kochenderfer and Tim A. Wheeler. *Algorithms for Optimization*. The MIT Press, 2019.

[RN09] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Prentice Hall Press, USA, 3rd edition, 2009.